Học tăng cường sâu tích hợp cơ chế tự chú ý và thông tin lưới điện cho bài toán quy hoạch trạm sạc xe điện

Vương Quang Huy*, Đào Quang Thái Anh* Nguyễn Gia Bảo* Trần Nam Sơn*
Nguyễn Văn Hiếu* Nguyễn Đình Chiến*
* *Trường Đại học Hà Nội*
Email: huyvq@hanu.edu.vn, thaianh494@gmail.com, nguyengiabaoctn@gmail.com, trannamson0328@gmail.com hieu9zabc@gmail.com, chiennguyen18125@gmail.com

***Tóm tắt nội dung*—Sự gia tăng nhanh của xe điện đặt ra yêu cầu quy hoạch hạ tầng sạc vừa đáp ứng nhu cầu sử dụng, vừa phù hợp với khả năng cung cấp của lưới điện đô thị. Bài báo đề xuất một mô hình học tăng cường sâu cho bài toán mở rộng mạng trạm sạc theo chuỗi quyết định, với trạng thái phản ánh nhu cầu thay đổi theo hạ tầng đã triển khai, mức ùn tắc tại trạm và dư địa công suất của lưới phân phối, còn hàm mục tiêu hợp nhất chất lượng phục vụ, chi phí người dùng, công bằng không gian và tác động lên lưới. Chính sách được học bằng Deep Q-Network với bộ mã hoá kết hợp cơ chế tự chú ý và lớp gộp Set Transformer, cho biểu diễn toàn cục có kích thước cố định. Trên mạng đường bộ và mô hình lưới điện phân phối mô phỏng của quận Đống Đa, phương pháp đề xuất đạt giá trị hàm mục tiêu tổng hợp cao nhất trong bốn phương án đối sánh, đồng thời sử dụng ngân sách hiệu quả và duy trì tải của lưới điện trong giới hạn cho phép.**

***Keywords*-trạm sạc xe điện; học tăng cường sâu; cơ chế tự chú ý; Set Transformer; lưới điện phân phối; quy hoạch hạ tầng đô thị**

I. Giới thiệu

Quá trình điện hóa giao thông đang diễn ra nhanh chóng tại các đô thị Việt Nam, kéo theo nhu cầu mở rộng mạng lưới trạm sạc công cộng [1], [2]. Tuy nhiên, tại các khu vực đô thị có mật độ cao, việc lựa chọn vị trí trạm sạc không chỉ phụ thuộc vào nhu cầu sử dụng mà còn bị chi phối bởi chi phí mặt bằng và khả năng đáp ứng của lưới điện phân phối. Do đó, quy hoạch trạm sạc cần đồng thời bảo đảm hiệu quả phục vụ và hạn chế tác động lên hạ tầng điện hiện hữu [3].

Bài toán có tính tuần tự vì mỗi quyết định triển khai đều làm thay đổi trạng thái của hệ thống. Khi một trạm mới được bổ sung, nhu cầu chưa được phục vụ tại khu vực lân cận giảm xuống, đồng thời công suất khả dụng của lưới điện cũng bị thu hẹp. Do đó, một vị trí phù hợp khi xét riêng lẻ chưa chắc còn tối ưu sau một chuỗi quyết định. Các phương pháp tham lam hoặc tối ưu tĩnh khó phản ánh đầy đủ sự phụ thuộc này, đặc biệt khi nhiều trạm được tập trung trong cùng một khu vực và cùng khai thác nguồn lực lưới điện có giới hạn.

Học tăng cường sâu (Deep Reinforcement Learning – DRL) là hướng tiếp cận tự nhiên cho bài toán tuần tự này: chúng tôi mô hình hoá nó dưới dạng quá trình quyết định Markov (Markov Decision Process – MDP) và học chính sách bằng mạng Q sâu (Deep Q-Network – DQN). Tác tử không chọn trực tiếp một nút trong hàng trăm ứng viên mà chọn một trong năm hành động mức cao (macro-action), rồi một heuristic xác định vị trí cụ thể. Bộ mã hoá vì vậy chỉ cần sinh *một* biểu diễn tóm tắt toàn mạng có kích thước cố định – điều mà việc làm phẳng đặc trưng nút bằng perceptron nhiều lớp (Multilayer Perceptron – MLP) không đáp ứng được vì phụ thuộc số nút, còn mạng nơ-ron đồ thị truyền thông điệp chỉ tổng hợp trong phạm vi lân cận giới hạn.

Gần nhất với nghiên cứu này là PPO-Attention [4], dùng cơ chế tự chú ý (self-attention) để mã hoá quan hệ giữa các nút. Kế thừa hướng đó, chúng tôi bổ sung lớp gộp bằng chú ý đa đầu (Pooling by Multi-head Attention – PMA) của Set Transformer [5]: self-attention cho mỗi nút tầm nhìn toàn cục, còn PMA nén tập embedding có số lượng thay đổi thành véc-tơ kích thước cố định, khớp với không gian năm macro-action.

Các đóng góp chính của bài báo gồm: (i) mô hình hoá bài toán mở rộng mạng trạm sạc dưới dạng MDP, đồng thời xét đến nhu cầu động và tác động tích luỹ lên lưới điện; (ii) đề xuất bộ mã hoá trạng thái kết hợp cơ chế tự chú ý và PMA để tạo ra biểu diễn toàn cục có kích thước cố định; và (iii) đánh giá phương pháp trên mạng đường bộ đô thị thông qua đối sánh với các phương pháp tham lam

và giải thuật di truyền.

II. Các nghiên cứu liên quan

Quy hoạch vị trí trạm sạc. Các nghiên cứu ban đầu về bài toán quy hoạch vị trí trạm sạc chủ yếu dựa trên các mô hình tối ưu cổ điển [6]. Trong quy hoạch trạm sạc xe điện, các mô hình quy hoạch nguyên hỗn hợp cũng được sử dụng để đồng thời xác định vị trí và cấu hình trạm [1], [2]. Mặc dù các phương pháp này có thể tìm được nghiệm tối ưu hoặc gần tối ưu ở quy mô vừa phải, chúng thường giả định nhu cầu và trạng thái lưới điện cố định trong quá trình tối ưu. Các phương pháp tiến hoá, chẳng hạn như giải thuật di truyền và các phương pháp lai [3], [7], có khả năng xử lý không gian tìm kiếm lớn hơn, nhưng vẫn chủ yếu xem bài toán dưới góc độ tĩnh và chưa trực tiếp khai thác sự phụ thuộc giữa các quyết định triển khai liên tiếp.

Học tăng cường cho quy hoạch trạm sạc. Học tăng cường sâu (Deep Reinforcement Learning – DRL) đã được áp dụng cho nhiều bài toán tối ưu tổ hợp trên đồ thị [8], cũng như các bài toán định vị và điều phối trạm sạc [9]–[11]. Khác với tối ưu tĩnh, DRL cho phép mô hình hoá quá trình triển khai dưới dạng các quyết định tuần tự và cập nhật chính sách dựa trên trạng thái hiện tại của hệ thống. Tuy nhiên, nhiều phương pháp vẫn giả định nhu cầu cố định hoặc sử dụng bộ mã hoá dựa trên mạng perceptron nhiều lớp (Multilayer Perceptron – MLP) và mạng nơ-ron đồ thị, trong đó thông tin chủ yếu được truyền qua các nút lân cận.

Cơ chế chú ý. Một hướng tiếp cận gần với nghiên cứu này là Proximal Policy Optimization kết hợp cơ chế chú ý (PPO-Attention) [4], trong đó cơ chế tự chú ý được sử dụng để trao đổi thông tin giữa các nút của mạng đường bộ khi lựa chọn vị trí trạm sạc. Kết quả cho thấy cơ chế chú ý có khả năng khai thác các mối quan hệ không gian trên phạm vi toàn mạng. Dựa trên hướng tiếp cận này, chúng tôi bổ sung cơ chế gộp bằng chú ý đa đầu (Pooling by Multi-head Attention – PMA) của Set Transformer [5] để tổng hợp tập biểu diễn nút có kích thước thay đổi thành một véc-tơ kích thước cố định. Cách biểu diễn này phù hợp với không gian hành động mức cao được sử dụng trong bài toán.

Khoảng trống chung là chưa kết hợp đồng thời ba yếu tố: triển khai tuần tự dưới giới hạn ngân sách, nhu cầu và dư địa lưới thay đổi theo các quyết định trước, và một bộ mã hoá toàn cục không phụ thuộc số nút. Bài báo giải quyết cả ba trong một khung thống nhất.

III. Phát biểu bài toán

A. Môi trường và hàm mục tiêu

Mạng đường bộ của khu vực nghiên cứu là đồ thị có thuộc tính $G = (V, E)$ trích xuất từ OpenStreetMap [12]: mỗi nút $v \in V$ mang toạ độ, nhu cầu cơ sở $\mathrm{dem}(v)$, giá đất và mật độ dân số; mỗi cạnh mang chiều dài đoạn đường. Một trạm $s = (v, \mathbf{t})$ đặt tại nút v lắp $\mathbf{t} = (t_1, \ldots, t_m)$ bộ sạc thuộc m mức công suất, tổng $n(s) = \sum_i t_i \le K$, cho công suất phục vụ $C(s) = \sum_i t_i c_i$ với c_i là công suất của bộ sạc loại i. Bán kính phục vụ tăng theo $C(s)$ rồi bão hoà tại $R_{\max}$, còn chi phí triển khai gồm tiền mặt bằng và giá thiết bị:

$$r(s) = \frac{R_{\max}}{1 + e^{-C(s)/C_0}}, \qquad \mathrm{fee}(s) = \mathrm{land}(v, s) + \sum_i t_i \kappa_i. \tag{1}$$

Một kế hoạch p là tập các trạm đã triển khai.

Chất lượng của p được đo bằng hàm mục tiêu tổng hợp $R(p)$ gồm bốn thành phần: lợi ích phục vụ, chi phí bất tiện, công bằng không gian và tác động lên lưới điện. Ba thành phần đầu được chuẩn hoá theo giá trị của chúng dưới hạ tầng hiện hữu p_0 để so sánh được giữa các khu vực.

Lợi ích phục vụ cân bằng hai góc nhìn: một nút được nhiều trạm phủ thì lợi ích biên giảm theo chuỗi điều hoà, qua đó phạt việc phủ trùng lặp; ngược lại một trạm càng vươn tới nhiều nút thì càng hữu ích:

$$\mathrm{benefit}(p) = \frac{1}{2}\left(\frac{1}{|V|} \sum_{v \in V} \sum_{k=1}^{\mathrm{cov}(v)} \frac{1}{k} + \frac{1}{|p|} \sum_{s \in p} \frac{\lambda_{\mathrm{sc}} |V_s|}{|V|} \right) \tag{2}$$

với $\mathrm{cov}(v)$ là số trạm phủ nút v và V_s là tập nút trạm s vươn tới. Chi phí bất tiện gộp thời gian đi lại (T_{tr}), thời gian chờ (T_w) và thời gian sạc (T_{ch}) dưới hệ số đánh đổi α, còn công bằng không gian là nghịch đảo độ lệch chuẩn σ_{cov} của độ phủ giữa các nút:

$$\begin{aligned} \mathrm{cost}(p) &= \tfrac{1}{3}\big[\alpha \hat{T}_{\mathrm{tr}} + (1-\alpha)(\hat{T}_{\mathrm{w}} + \hat{T}_{\mathrm{ch}})\big], \\ \mathrm{fairness}(p) &= \big(1 + \sigma_{\mathrm{cov}}\big)^{-1}, \\ T_{\mathrm{tr}} &= \sum_{v \in V} \big(1 + \mathrm{dem}(v)\big) d_v, \quad T_{\mathrm{w}} = \sum_{s \in p} D_s W_s, \\ T_{\mathrm{ch}} &= \sum_{s \in p} D_s / \mu_s. \end{aligned} \tag{3}$$

Ở đây, d_v là khoảng cách từ nút v đến trạm được gán, D_s và μ_s lần lượt là cường độ tới và tốc độ phục vụ của trạm s, W_s là thời gian chờ trung bình, và $\hat{T} = T(p)/T(p_0)$ là dạng đã chuẩn hóa. Mỗi nút được gán vào trạm sao cho tổng chi phí di chuyển và chờ đợi được tối thiểu hóa, nên trạm được chọn

không nhất thiết là trạm gần nhất. Thời gian chờ được tính bằng mô hình hàng đợi M/M/1/N với sức chứa hữu hạn, cho phép phản ánh ổn định tình trạng tắc nghẽn khi cường độ tới của trạm tăng cao.

B. Nhu cầu động

Việc lắp đặt một trạm đáp ứng nhu cầu tại chỗ và do đó làm giảm nhu cầu biên của các nút lân cận:

$$\mathrm{dem}_{\mathrm{dyn}}(v,p) = \mathrm{dem}(v)\exp\Big(-\eta \sum_{\substack{s\in p \\ d_{v,s}<r(s)}} C(s)\, e^{-\beta d_{v,s}}\Big) \tag{4}$$

với $d_{v,s}$ là khoảng cách Haversine từ nút v đến trạm s, $\eta > 0$ là hệ số điều chỉnh theo công suất tích lũy và $\beta > 0$ là hệ số suy giảm theo khoảng cách. Khi công suất trong bán kính $r(s)$ tăng, nhu cầu chưa đáp ứng giảm theo hàm mũ, qua đó hạn chế tập trung trạm trong cùng một khu vực; giá trị này được dùng làm đặc trưng nút (Mục IV-A) và định hướng macro-action theo nhu cầu (Bảng I).

C. Hàm phạt lưới điện

Mỗi nút v được gán trước cho thanh cái trung áp gần nhất $b(v) \in \mathcal{B}_d$, với khoảng cách đấu nối $\delta(v)$. Thanh cái b có dư địa công suất $A_b = \lambda S^{\max} - P_b^{\mathrm{load}}$ sau phụ tải nền, trong đó $S^{\max}$ là công suất định mức của xuất tuyến và λ là hệ số mang tải cho phép; kế hoạch p rút từ nó công suất $Q_b = \sum_{s:\, b(v_s)=b} C(s)$. Hàm phạt lưới gồm khoảng cách đấu nối đã chuẩn hoá $\hat{\delta}(v_s) \in [0,1]$ và mức vượt dư địa cộng dồn tại mỗi thanh cái:

$$\Phi_{\mathrm{grid}}(p) = \frac{1}{\max(1,|p|)} \sum_{s\in p} \hat{\delta}(v_s) + \frac{1}{|\mathcal{B}_d|} \sum_{b\in\mathcal{B}_d} \min\left(\frac{\max(0, Q_b - A_b)}{\max(A_b, A_{\min})},\ \Psi\right) \tag{5}$$

với tỉ lệ quá tải chặn dưới bởi $A_{\min}$ và chặn trên bởi Ψ. Hàm mục tiêu tổng hợp được xác định bởi

$$R(p) = \frac{\mathrm{benefit}(p) - \mathrm{cost}(p) + \mathrm{fairness}(p)}{3} - w_g\, \Phi_{\mathrm{grid}}(p) \tag{6}$$

trong đó w_g là trọng số tác động lưới điện.

D. Tổng hợp bài toán

Cho đồ thị G, kế hoạch hiện hữu p_0, ngân sách B và tập thanh cái $\mathcal{B}_d$ kèm dư địa A_b, cần tìm kế hoạch mở rộng $p \supseteq p_0$ – tức vị trí đặt trạm và cấu hình bộ sạc tại mỗi trạm – tối đa hoá hàm mục tiêu tổng hợp ròng:

$$p^\star = \arg\max_{p\supseteq p_0} R(p) \tag{7}$$

$$\text{v.đ.k} \quad \sum_{s\in p} \mathrm{fee}(s) - \sum_{s\in p_0} \mathrm{fee}(s) \le B \tag{8}$$

$$n(s) \le K \qquad \forall s \in p^\star \tag{9}$$

Dung lượng lưới tham gia $R(p)$ qua số hạng phạt Φ_{grid} ở (5): mức vượt dư địa càng lớn thì điểm càng thấp, nhờ đó tác tử nhận được tín hiệu định lượng về mức độ quá tải ở mọi bước quyết định. Việc chọn đồng thời vị trí và cấu hình bộ sạc trên mọi nút khiến tìm kiếm vét cạn bất khả thi ở quy mô một quận, và đó là lý do chúng tôi học chính sách theo cách trình bày ở Mục IV.

Bảng I: KHÔNG GIAN MACRO-ACTION

Macro-action	**Cách chọn nút**
Tạo theo lợi ích	Nút trống tối đa hoá độ phủ tiềm năng, chiết khấu theo lợi ích của các trạm lân cận.
Tạo theo nhu cầu	Nút trống có $\mathrm{dem}_{\mathrm{dyn}}(v,p_t)$ lớn nhất.
Bổ sung theo lợi ích	Cùng quy tắc lợi ích, giới hạn ở nút đã có trạm với $< K$ bộ sạc; thêm một bộ sạc.
Bổ sung theo nhu cầu	Cùng quy tắc nhu cầu dưới cùng giới hạn.
Di dời	Chuyển một bộ sạc từ trạm lợi ích thấp nhất sang trạm có thời gian chờ tệ nhất.

IV. Phương pháp đề xuất

A. Quá trình quyết định Markov

Trạng thái $s_t = (\mathbf{X}_t, g_t)$ gồm ma trận đặc trưng nút $\mathbf{X}_t \in \mathbb{R}^{|V|\times 10}$ – mỗi hàng chứa toạ độ, nhu cầu tĩnh và động, giá đất, mật độ đường, công suất đã lắp tại nút, khoảng cách đấu nối $\delta(v)$, dung lượng còn lại của thanh cái cục bộ $A_{b(v)} - Q_{b(v)}$, và khoảng cách tới trạm gần nhất – cùng mô tả toàn cục $g_t \in \mathbb{R}^3$ (ngân sách còn lại, tiến độ episode, mức cải thiện điểm). Mọi đặc trưng được co giãn về $[-1,1]$ theo hằng số chuẩn hoá riêng của từng quận.

Hành động là một trong năm macro-action (Bảng I). Chính sách trước tiên chọn một *chiến lược*, sau đó heuristic tương ứng xác định nút cụ thể để thực hiện hành động. Với hai hành động *tạo mới*, cấu hình bộ sạc được chọn từ bảng tra ngoại tuyến, trong đó lưu tổ hợp có chi phí thấp nhất cho từng mức công suất.

Phần thưởng. Gọi R_t^* là điểm tốt nhất quan sát được trong episode tính đến bước t:

$$r_t = \underbrace{R(p_t) - R(p_{t-1})}_{\text{định hình}} + w_b \underbrace{\max\big(0,\ R(p_t) - R_{t-1}^*\big)}_{\text{thưởng phá kỷ lục}} \tag{10}$$

Trong đó, số hạng đầu phản ánh mức cải thiện hàm mục tiêu giữa hai bước liên tiếp theo phương pháp định hình phần thưởng [13], còn số hạng thứ hai thưởng bổ sung khi kế hoạch đạt kỷ lục mới trong episode ($R(p_t) > R_{t-1}^*$). Ở đây, w_b là trọng số thưởng phá kỷ lục và R_{t-1}^* là giá trị tốt nhất trước bước t. Episode kết thúc khi hết ngân sách, toàn bộ nút đã có trạm, hoặc đạt số bước tối đa $T_{\max}$.

B. Bộ mã hoá tự chú ý và lớp gộp Set Transformer

Kế thừa PPO-Attention [4], bộ mã hoá của chúng tôi (Hình 1) bổ sung ba điểm.

Thứ nhất, tự chú ý toàn cục. Mọi nút chú ý tới toàn bộ các nút khác ngay từ lớp đầu tiên, thay vì chỉ các nút kề, giúp mở rộng tầm nhìn toàn cục mà không cần ma trận kề. Mỗi khối dùng Transformer encoder tiền chuẩn hoá:

$$\begin{aligned} h &\leftarrow h + \mathrm{MHA}\big(\mathrm{LN}(h), \mathrm{LN}(h), \mathrm{LN}(h)\big) \\ h &\leftarrow h + \mathrm{FF}\big(\mathrm{LN}(h)\big) \end{aligned} \tag{11}$$

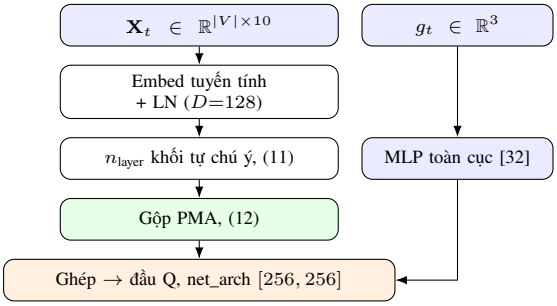
Thứ hai, gộp theo Set Transformer. Sau các khối tự chú ý, cơ chế Pooling by Multi-head Attention [5] sử dụng n_{seed} véc-tơ truy vấn *học được* để tổng hợp thông tin từ toàn bộ embedding của các nút $h \in \mathbb{R}^{|V|\times D}$:

$$\mathrm{pooled} = \mathrm{LN}\big(\mathrm{seed} + \mathrm{MHA}(\mathrm{seed}, h, h)\big) \tag{12}$$

Đầu ra có kích thước cố định $n_{\text{seed}} \times D$, không phụ thuộc số lượng nút, phù hợp với không gian năm macro-action.

Thứ ba, LayerNorm thay cho BatchNorm. Do kích thước lô có thể thay đổi giữa lúc tương tác với môi trường và cập nhật gradient, LayerNorm giúp duy trì ổn định trong cả hai giai đoạn.

Véc-tơ pooled được ghép với đầu ra MLP của g_t và đưa vào đầu ước lượng giá trị hành động của DQN [14]. Mô hình được tối ưu bằng hàm mất mát TD trên bộ đệm phát lại. Chúng tôi sử dụng Stable-Baselines3 [15] với các siêu tham số trong Bảng II, gradient clipping ở chuẩn 1,0 và seed cố định để bảo đảm khả năng tái lập. Thuật toán 1 tóm tắt quá trình tương tác trong một episode.



Hình 1: Bộ mã hoá đề xuất. Lớp gộp PMA đảm bảo kích thước đầu ra độc lập với $|V|$.

Bảng II: SIÊU THAM SỐ MÔ HÌNH

Bộ mã hoá		**Huấn luyện DQN**	
D	128	bộ đệm phát lại	20 000
số đầu chú ý	4	kích thước lô	128
n_{layer}	2	tốc độ học	10^{-4}
n_{seed}	5	ε: 1,0 → 0,05	50% số bước
hệ số FF	4	cập nhật mạng đích	1000 bước
dropout	0,0	tổng số bước	120 000

V. THIẾT LẬP THỰC NGHIỆM

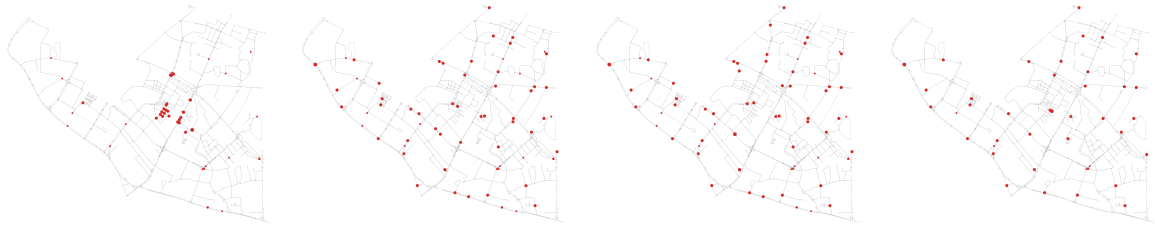
Dữ liệu. Chúng tôi dùng đồ thị đường bộ OpenStreetMap [12] của quận Đống Đa, Hà Nội ($|V| = 639$). Lưới điện phân phối được mô phỏng dựa trên toạ độ và công suất định mức của các trạm biến áp 500/220/110 kV thực tế, với các xuất tuyến 22 kV giả định chạy dọc mạng đường bộ và $S^{\max} = 16{,}0$ MVA đồng nhất; tại $\lambda = 0{,}8$ mỗi thanh cái cung cấp 12,8 MW. Quận trải trên 18 thanh cái, với tổng dư địa 173,1 MW sau phụ tải nền được mô phỏng theo dân số và điểm thu hút, không sử dụng dữ liệu phụ tải vận hành thực tế. Dư địa này không đồng đều giữa các thanh cái, nên chính sách phải cân đối vị trí trạm theo dung lượng còn lại của từng thanh cái.

Algorithm 1 Mở rộng kế hoạch trạm sạc bằng DQN

```
p ← p_0, ngân sách B, R* ← R(p_0)
while B > 0 và t < T_max do
    Mã hoá s_t theo (11)–(12);
    a_t ← arg max_a Q_θ(s_t, a)
    Chọn nút theo heuristic của a_t; cập nhật p, B, Q_b
    Tính r_t theo (10); cập nhật R*, p*
end while
return p*
```

Bảng III: SO SÁNH HIỆU NĂNG TRÊN QUẬN ĐỐNG ĐA. MỌI GIÁ TRỊ QUY VỀ PHẦN TRĂM SO VỚI HẠ TẦNG HIỆN HỮU (= 100). QUÁ TẢI, SỐ TRẠM VÀ NGÂN SÁCH ĐƯỢC BÁO CÁO THEO GIÁ TRỊ THỰC TẾ. KẾT QUẢ CỦA CÁC PHƯƠNG PHÁP NGẪU NHIÊN ĐƯỢC BÁO CÁO DƯỚI DẠNG MEAN ± STD.

Phương pháp	$R(p)$ ↑	Lợi ích ↑	Chi phí ↓	Công bằng ↑	Quá tải ↓	Số trạm	Ngân sách (%)
Hạ tầng hiện hữu	100,0	100,0	100,0	100,0	0	5	0,0
Greedy-Benefit	150,3	191,9	56,8	15,1	1	47	56,6
Greedy-Demand	210,8	215,6	66,1	41,2	1	67	98,4
Giải thuật di truyền	217,1 ± 3,8	212,0 ± 3,9	45,2 ± 1,3	40,9 ± 0,4	0	65	98,0
DQN (đề xuất)	224,7 ± 0,3	232,9 ± 1,9	48,3 ± 0,4	47,8 ± 1,4	0	46	90,1



(a) Greedy-Benefit (b) Greedy-Demand (c) Giải thuật di truyền (d) DQN đề xuất

Hình 2: Bản đồ triển khai trạm sạc trên quận Đống Đa. Kích thước điểm đánh dấu tỉ lệ với công suất lắp đặt của trạm.

Bảng IV: PHÂN TÍCH LOẠI BỎ CÁC THÀNH PHẦN MÔ HÌNH

Mô hình	$R(p)$ ↑	Lợi ích ↑	Công bằng ↑	Quá tải ↓
DQN đầy đủ	224,7 ± 0,3	232,9 ± 1,9	47,8 ± 1,4	0
Không xét lưới	220,7 ± 0,6	237,4 ± 1,7	30,7 ± 1,8	2
Mean Pooling	225,4 ± 1,7	235,6 ± 3,3	46,3 ± 3,5	0
Không chú ý (MLP)	222,5 ± 2,6	220,8 ± 4,9	43,7 ± 5,2	0

Đối sánh và độ đo. Mọi phương pháp dùng cùng p_0, ngân sách, đồ thị và seed; DQN và giải thuật di truyền được đánh giá qua 5 lần chạy độc lập (mean ± std). Các độ đo chuẩn hoá theo hạ tầng hiện hữu (= 100); quá tải, số trạm và ngân sách (%) báo cáo theo giá trị thực.

VI. Kết quả và thảo luận

So sánh tổng thể. Bảng III cho thấy DQN đạt giá trị hàm mục tiêu tổng hợp cao nhất (224,7 ± 0,3), vượt Giải thuật di truyền (217,1 ± 3,8), Greedy-Demand (210,8) và Greedy-Benefit (150,3). Đồng thời, DQN chỉ sử dụng 46 trạm và 90,1% ngân sách, ít hơn lần lượt 19 trạm và 7,9% ngân sách so với Giải thuật di truyền. Độ lệch chuẩn nhỏ cho thấy DQN có tính ổn định cao hơn phương pháp tiến hóa.

Lưới điện và phân bố không gian. DQN và Giải thuật di truyền đều không gây quá tải thanh cái, trong khi hai phương pháp tham lam đều gây quá tải 1 thanh cái. Trường hợp Greedy-Benefit cho thấy quá tải phụ thuộc nhiều vào vị trí phân bố hơn số lượng trạm. Nhờ xét dung lượng dư của 18 thanh cái, DQN tránh tập trung tải lên cùng một xuất tuyến. DQN đồng thời đạt lợi ích (232,9 ± 1,9) và công bằng (47,8 ± 1,4) cao nhất, như minh họa ở Hình 2.

Nghiên cứu loại bỏ thành phần. Bảng IV cho thấy đóng góp của các thành phần kiến trúc. Bỏ thành phần lưới (Không xét lưới) làm lợi ích tăng nhẹ (237,4 ± 1,7) nhưng gây quá tải 2 thanh cái và giảm mạnh công bằng xuống 30,7±1,8. Thay PMA bằng Mean Pooling cho giá trị hàm mục tiêu tương đương (225,4 ± 1,7) nhưng độ lệch chuẩn tăng từ ±0,3 lên ±1,7 và công bằng giảm xuống 46,3±3,5, cho thấy PMA cải thiện tính ổn định. Khi loại bỏ tự chú ý (MLP), giá trị hàm mục tiêu giảm xuống 222,5 ± 2,6 và lợi ích xuống 220,8 ± 4,9, xác nhận vai trò của cơ chế chú ý trong tổng hợp quan hệ giữa các nút.

VII. Kết luận

Bài báo đề xuất mô hình DQN tích hợp thông tin lưới điện cho bài toán mở rộng mạng trạm sạc theo chuỗi quyết định, với bộ mã hóa trạng thái

kết hợp cơ chế tự chú ý và lớp gộp PMA của Set Transformer. Thực nghiệm trên quận Đống Đa cho thấy phương pháp đề xuất đạt giá trị hàm mục tiêu tổng hợp cao nhất ($224{,}7 \pm 0{,}3$), không gây quá tải lưới và chỉ sử dụng $90{,}1\%$ ngân sách, qua đó cho thấy hiệu quả và tính ổn định so với các phương pháp đối sánh. Nghiên cứu loại bỏ thành phần xác nhận vai trò của thành phần lưới trong kiểm soát quá tải và cải thiện công bằng, đồng thời PMA giúp tăng tính ổn định của mô hình.

Nghiên cứu hiện còn một số hạn chế do mô hình lưới phân phối và phụ tải nền được xây dựng từ dữ liệu mô phỏng thay vì dữ liệu vận hành thực tế, đồng thời thực nghiệm mới chỉ được tiến hành trên một khu vực đô thị. Trong tương lai, nghiên cứu sẽ mở rộng đánh giá trên các mạng đường bộ có quy mô và đặc trưng khác nhau, tích hợp dữ liệu lưới điện thực tế, đồng thời xem xét thiên kiến khoảng cách trong cơ chế chú ý và khả năng chuyển giao chính sách giữa các khu vực.

TÀI LIỆU

[1] M. Veisi, H. Naderian, and M. Karimi, "Optimal charging station placement of electric vehicles in the smart distribution network based on the mixed integer linear programming," *International Journal of Electrical Power & Energy Systems*, vol. 168, p. 110675, 2025.

[2] Q. V. Truc, M. H. Hien, and H. V. Tuan, "Electric vehicle charging stations placement optimization in Vietnam using mixed-integer nonlinear programming model," *arXiv preprint arXiv:2412.16025*, 2024.

[3] B. A. Kumar, B. Jyothi, A. R. Singh, M. Bajaj, R. S. Rathore, and M. B. Tuka, "Hybrid genetic algorithm-simulated annealing based electric vehicle charging station placement for optimizing distribution network resilience," *Scientific Reports*, vol. 14, no. 1, p. 7637, 2024.

[4] J. Liu, J. Sun, and X. Qi, "Optimal placement of charging stations in road networks: A reinforcement learning approach with attention mechanism," *Applied Sciences*, vol. 13, no. 14, p. 8473, 2023.

[5] J. Lee, Y. Lee, J. Kim, A. Kosiorek, S. Choi, and Y. W. Teh, "Set transformer: A framework for attention-based permutation-invariant neural networks," in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, vol. 97. PMLR, 2019, pp. 3744–3753.

[6] S. L. Hakimi, "Optimum locations of switching centers and the absolute centers and medians of a graph," *Operations Research*, vol. 12, no. 3, pp. 450–459, 1964.

[7] G. Zhou, Z. Zhu, and S. Luo, "Location optimization of electric vehicle charging stations: Based on cost model and genetic algorithm," *Energy*, vol. 247, p. 123437, 2022.

[8] H. Dai, E. B. Khalil, Y. Zhang, B. Dilkina, and L. Song, "Learning combinatorial optimization algorithms over graphs," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 6348–6358.

[9] I. Ioannou, C. Christophorou, C. Politi, S. Denazis, M. Raspopoulos, and V. Vassiliou, "A deep Q-network (DQN) framework for joint optimization of EV charging station placement and vehicle routing," in *2025 IEEE International Smart Cities Conference (ISC2)*. IEEE, 2025, pp. 1–6.

[10] S. Padmanabhan, A. Petratos, A. Ting, K. Zhou, D. Hageman, J. R. Pisel, and M. J. Pyrcz, "Optimal placement of public electric vehicle charging stations using deep reinforcement learning," *arXiv preprint arXiv:2108.07772*, 2021.

[11] L. Von Wahl, N. Tempelmeier, A. Sao, and E. Demidova, "Reinforcement learning-based placement of charging stations in urban road networks," in *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2022, pp. 3992–4000.

[12] G. Boeing, "OSMnx: New methods for acquiring, constructing, analyzing, and visualizing complex street networks," *Computers, Environment and Urban Systems*, vol. 65, pp. 126–139, 2017.

[13] A. Y. Ng, D. Harada, and S. Russell, "Policy invariance under reward transformations: Theory and application to reward shaping," in *Proceedings of the 16th International Conference on Machine Learning (ICML)*, 1999, pp. 278–287.

[14] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski *et al.*, "Human-level control through deep reinforcement learning," *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.

[15] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dormann, "Stable-baselines3: Reliable reinforcement learning implementations," *Journal of Machine Learning Research*, vol. 22, no. 268, pp. 1–8, 2021.